TOR VERGATA
UNIVERSITÀ DEGLI STUDI DI ROMA
Software Engineering in Rome

Machine Learning for Software Engineering

STUDIO SULL'ACCURATEZZA DI MODELLI PREDITTIVI PER LA LOCALIZZAZIONE DI BUG NEL CODICE DI AMPIE APPLICAZIONI OPEN-SOURCE

ANDREA PEPE - MATR. 0315903

Agenda

- Introduzione ed obiettivi
- Progettazione
  - Metodologia ed assunzioni
  - Raccolta dei dati
  - Valutazione dei classificatori
  - Tecniche considerate per il confronto tra i classificatori
- Risultati
- Considerazioni e conclusioni

Introduzione ed obiettivi

- Tutti i processi di sviluppo software prevedono attività di testing, il cui obiettivo è l'individuazione di eventuali malfunzionamenti presenti nel sistema, spesso causati da bug nel codice sorgente.

- Su progetti di dimensioni notevoli, l'effort necessario per l'individuazione dei bug cresce considerevolmente. Il budget a disposizione, sia in termini economici che di tempo, è sempre limitato e non tutto può essere testato.

- Come fare per migliorare l'efficacia del testing? Come fare per scovare più bug possibili?

OBIETTIVO n° 1

Supportare l'attività di testing, indicando quali classi software conviene testare, stimando la probabilità che tali classi contengano dei bug.

Introduzione ed obiettivi

- Per perseguire l'obiettivo fissato in precedenza, è necessario un **modello predittivo**, in grado di prevedere quali classi hanno maggior probabilità di contenere dei bug.

- Un modello predittivo, in quanto tale, necessita di **dati passati** per effettuare le previsioni. Bisognerà dunque raccogliere tali dati ed effettuare delle misurazioni sul codice e sulla sua evoluzione release per release.

- A questo punto, si potrà fare ricorso a strumenti di Machine Learning, usando i classificatori considerati più opportuni e scegliendo le tecniche ritenute più adatte agli scopi che si intende raggiungere.

Obiettivo dello studio

- Come caso di studio, sono stati selezionati due progetti open-source di Apache:
  - Apache BookKeeper
  - Apache Syncope
- Sono stati selezionati *Random Forest, Naïve Bayes* ed *IBK* come classificatori da analizzare.
- Le tecniche di utilizzo considerate per tali classificatori sono la **feature selection**, il **sampling**, e la **cost sensitivity**. Per non complicare eccessivamente lo studio, due di tali tecniche sono state fissate e sono stati analizzati i risultati ottenuti sperimentando l'utilizzo di diverse varianti della terza tecnica.

OBIETTIVO n° 2

Individuare quale classificatore ha le migliori performances in termini di accuratezza delle predizioni, al variare delle tecniche di utilizzo, in particolare al variare della tipologia di cost sensitivity.

Progettazione: metodologia ed assunzioni

- Per la raccolta dei dati passati, è stato necessario individuare tutte le releases dei progetti e lo storico dei bug, con le informazioni sul ciclo di vita di questi ultimi: **injected version** (IV), **opening version** (OV) e **fixed version** (FV). A tale scopo, sono state utilizzate le API REST dell'Issue Tracking System *Jira.*

- Sono stati filtrati solo i tickets relativi ad issues di tipo *Bug*, con risoluzione *Fixed* e con stato *Resolved* oppure *Closed,* collezionandoli in una lista.

- La lista di bug è stata ordinata temporalmente e sono stati scartati quei bug per cui una delle seguenti condizioni era vera:
  - La FV è indicata tra le Affected Versions
  - IV > OV

- Per i bug che non avevano una IV esplicitamente indicata, è stata usata la tecnica di **Proportion Incremental**, considerando solo i bug precedenti a quello in analisi per il calcolo del fattore di proporzione **p**. Tale scelta è stata dettata dal non voler utilizzare dati futuri per fare delle stime su dati passati, in modo da non influenzare la successiva valutazione dei classificatori, effettuata con la tecnica **Walk Forward**.

Progettazione: raccolta dei dati

- Incrociando i tickets dei bug fixati ottenuti da *Jira* con i commit effettuati nel tempo sui progetti analizzati, ottenuti tramite il Version Control System *Git,* è stato possibile individuare i commit di fix.

- Inoltre, sempre tramite *Git*, sono stati scanditi tutti i commit dei progetti per effettuare le misurazioni necessarie sulle diverse classi software.

- In questo modo, è stato costruito un **dataset** in cui ogni riga **(istanza)** è costituita da una classe software, misurata al termine di una determinata release, caratterizzata dalle **metriche** computate ed **etichettata** con l'attributo *true* se la classe era buggy in quella release, *false* altrimenti.

ASSUNZIONE: per effettuare il **labeling** (buggy VS no buggy), si è assunto che tutte le classi toccate dal commit di fix del bug B, siano classificate come buggy in tutte le affected versions del bug B.

Progettazione: problema dello Snoring

- Siamo sicuri che una classe etichettata come “non buggy” in una release X sia effettivamente tale?

NO!

- È possibile che la classe, seppur classificata come “non buggy”, avesse uno o più **bug dormienti** nella release X, che si sono manifestati solo successivamente o che addirittura devono ancora manifestarsi → fenomeno dello **Snoring**

- Per releases recenti, l’impatto dello Snoring è molto elevato ed il labeling sarebbe inaffidabile, compromettendo la bontà delle predizioni dei classificatori.

- Si decide, quindi, di sfruttare i dati di tutte le releases a disposizione per la costruzione del dataset, ma la valutazione dei classificatori verrà fatta prendendo in considerazione unicamente il dataset troncato fino alla **prima metà delle releases**, così da limitare gli effetti dello Snoring.

Progettazione: metriche considerate

Nome metrica	Descrizione
Size	Dimensione in LOC della classe (cumulativa tra le releases)
LOC_touched	Numero di LOC aggiunte e rimosse nella release
LOC_added	Numero di LOC aggiunte nella release
MAX_LOC_added	Numero massimo di LOC aggiunte in una revisione della release
AVG_LOC_added	Numero medio di LOC aggiunte sulle revisioni della release
NR	Numero di revisioni nella specifica release
NAuth	Numero di differenti autori che hanno effettuato una revisione sulla classe nella release
Churn	LOC aggiunte – LOC rimosse nella release
MAX_Churn	Massimo churn di una revisione nella release
AVG_Churn	Churn medio tra le revisioni nella release
NFix	Numero di bug fixati nella classe (cumulativa tra le releases)
Age	Età della classe in settimane (cumulativa tra le releases)
WeightedAge	Età della classe pesata sulle LOC touched (cumulativa tra le releases)

Progettazione: valutazione dei classificatori

- Come accennato in precedenza, la tecnica di valutazione dei classificatori utilizzata è stata **Walk Forward.** Si tratta di una tecnica di tipo time-series, in cui l'ordine temporale dei dati è un requisito fondamentale.

- Ad ogni run, tutte le releases di training set **NON** devono essere influenzati dalle informazioni ottenibili nelle releases successive: in altre parole, se il training set è composto dalle releases *1, 2, ..., n*, allora le informazioni ottenibili dalla release *n+1* in poi non devono in alcun modo influenzarlo.

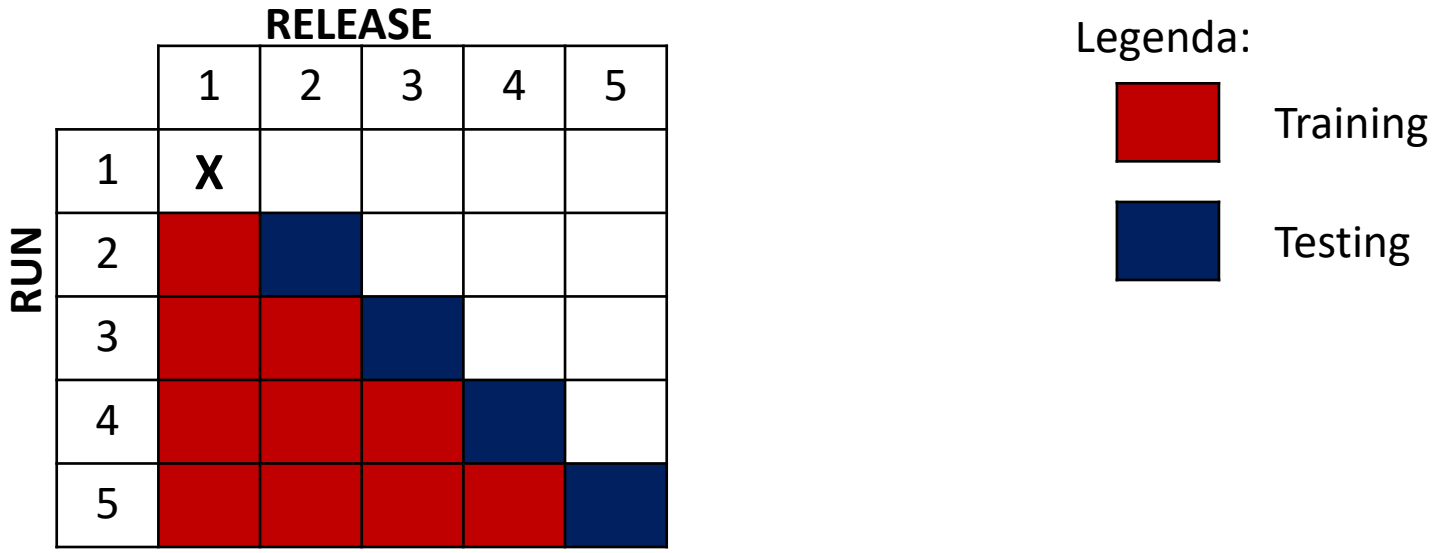

Progettazione: tecniche considerate per i classificatori

- Ottenuti i dataset e stabilita la tecnica di valutazione per i classificatori *Random Forest, Naive Bayes* e *IBK,* si è proceduto con la loro valutazione.

- In particolare, è stata osservata l'accuratezza dei diversi classificatori, mantenendo fisse le tecniche di feature selection e sampling, mentre sono state considerate le **diverse varianti della tecnica di cost sensitivity**.

- **Feature selection**: è stato applicato l'algoritmo greedy ***Backward Search,*** poiché il numero delle metriche considerate nel dataset non è così elevato da causare un severo degrado delle prestazioni rispetto a *Forward Search.* Inoltre, l'obiettivo era quello di eliminare metriche superflue, piuttosto che restringere il più possibile il pool delle metriche considerate.

- **Sampling**: per BookKeeper, le istanze buggy sono risultate essere il 12.98% delle totali, mentre, per Syncope, esse ammontano al 16.03% del totale. Si è scelto di applicare ***Undersampling*** per bilanciare il dataset.

- **Cost sensitivity**: tre scenari → *No Cost Sensitivity, Sensitive Threshold, Sensitive Learning*

Progettazione: varianti di Cost Sensitivity

- Se non viene applicata **nessuna tecnica di Cost Sensitivity**, una previsione errata ha sempre lo stesso peso, a prescindere se si sia ottenuto un falso positivo (FP) o un falso negativo (FN).

- Con **Sensitive Threshold**, si usa una matrice dei costi per ricalcolare la probability threshold usata dai classificatori; tale valore viene usato per definire quale dei due esiti predirre (buggy / non buggy).

- Con **Sensitive Learning**, si usa la medesima matrice dei costi ($\mathbf{CFN} = \mathbf{10} \cdot \boldsymbol{CFP}$) di *Sensitive Threshold*, ma, anziché cambiare il valore della probability threshold, si attua internamente una sorta di learning di un nuovo classificatore, con le istanze del dataset riconsiderate con il peso opportuno.

- Per l'applicazione di tali tecniche e la valutazione dei classificatori, sono state utilizzate le *Weka API.*

CTP = 0	CFN = 10
CFP = 1	CTN = 0

Matrice dei costi

Risultati

- Nelle slides seguenti, verranno mostrati dei box plot raffiguranti i risultati ottenuti dalla valutazione dei tre classificatori, sia per il progetto *BookKeeper,* che per il progetto *Syncope.*

- Il confronto verrà fatto sempre a parità di tecniche utilizzate.

- Le metriche prese in considerazione per valutare i classificatori sono:
  - *Precision*
  - *Recall*
  - *AUC (Area Under ROC Curve)*
  - *Kappa*

Risultati: BookKeeper – No Cost Sensitivity

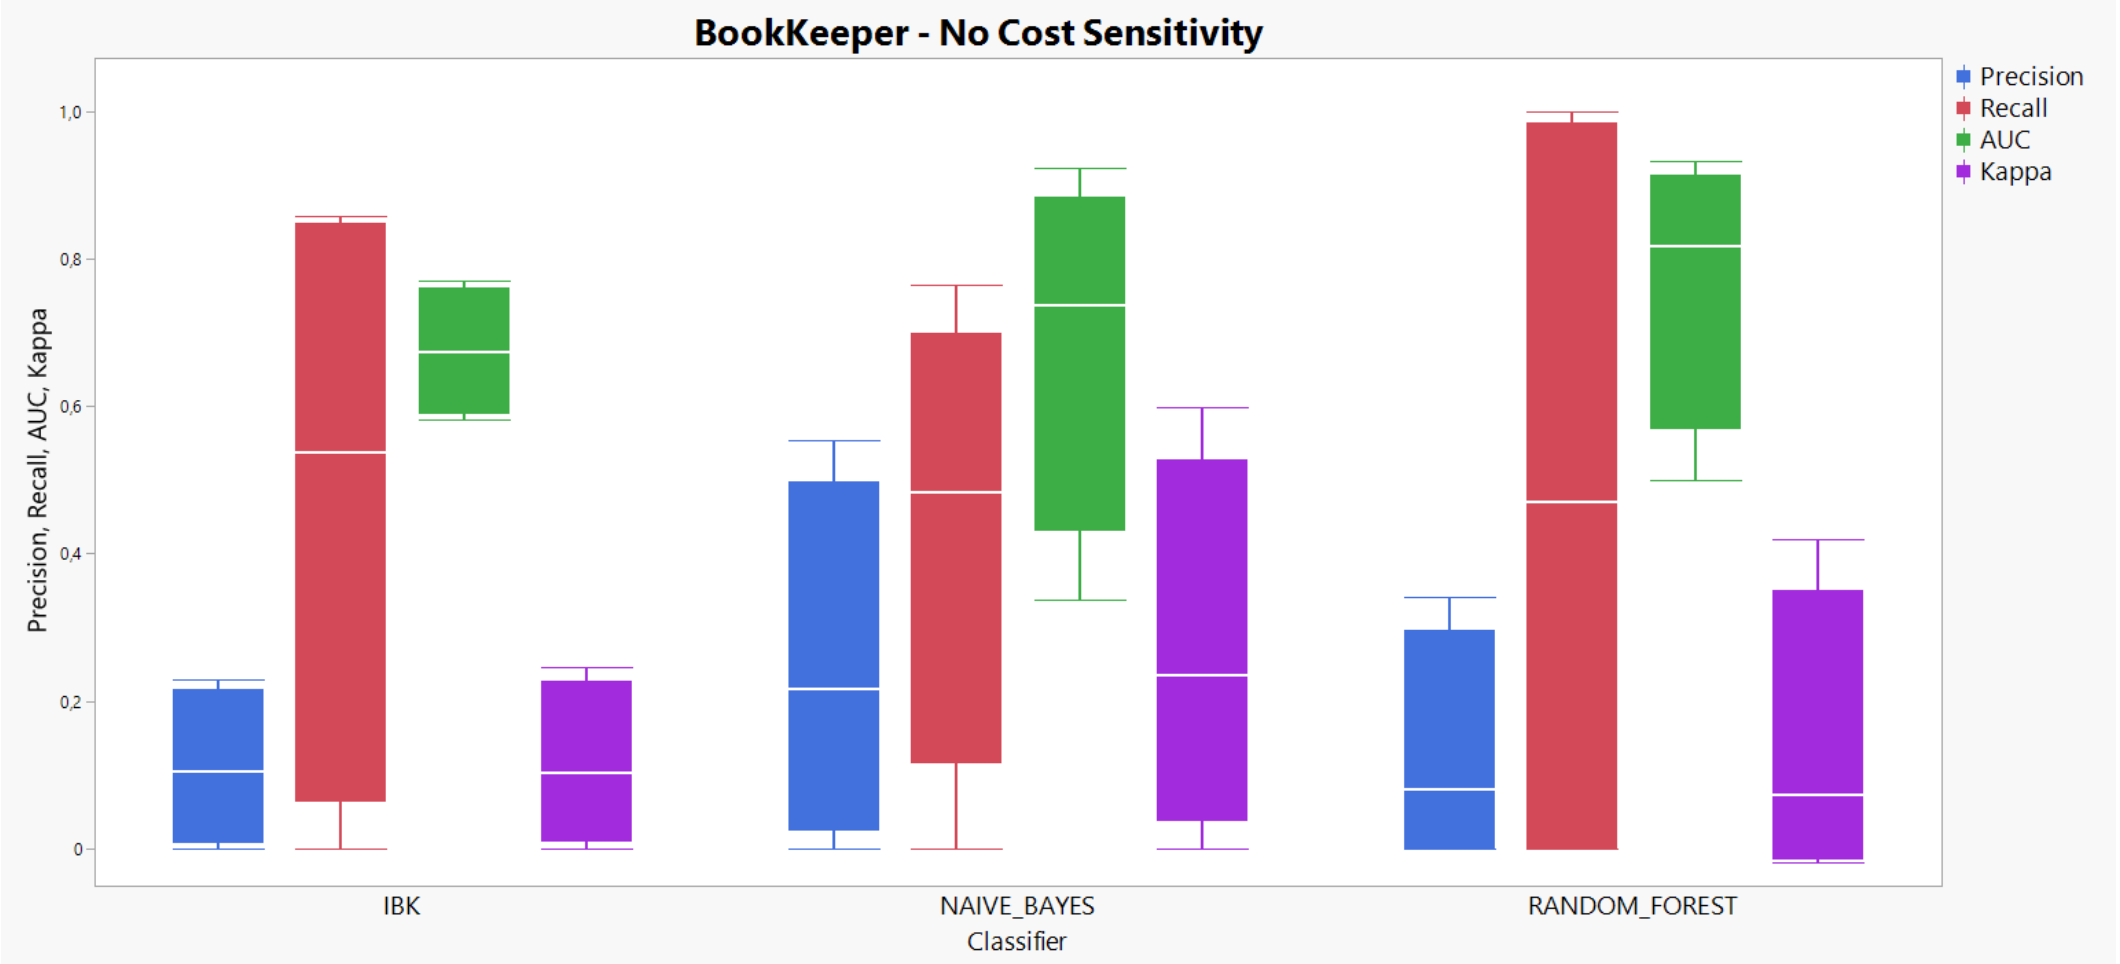

Risultati: BookKeeper – Sensitive Threshold

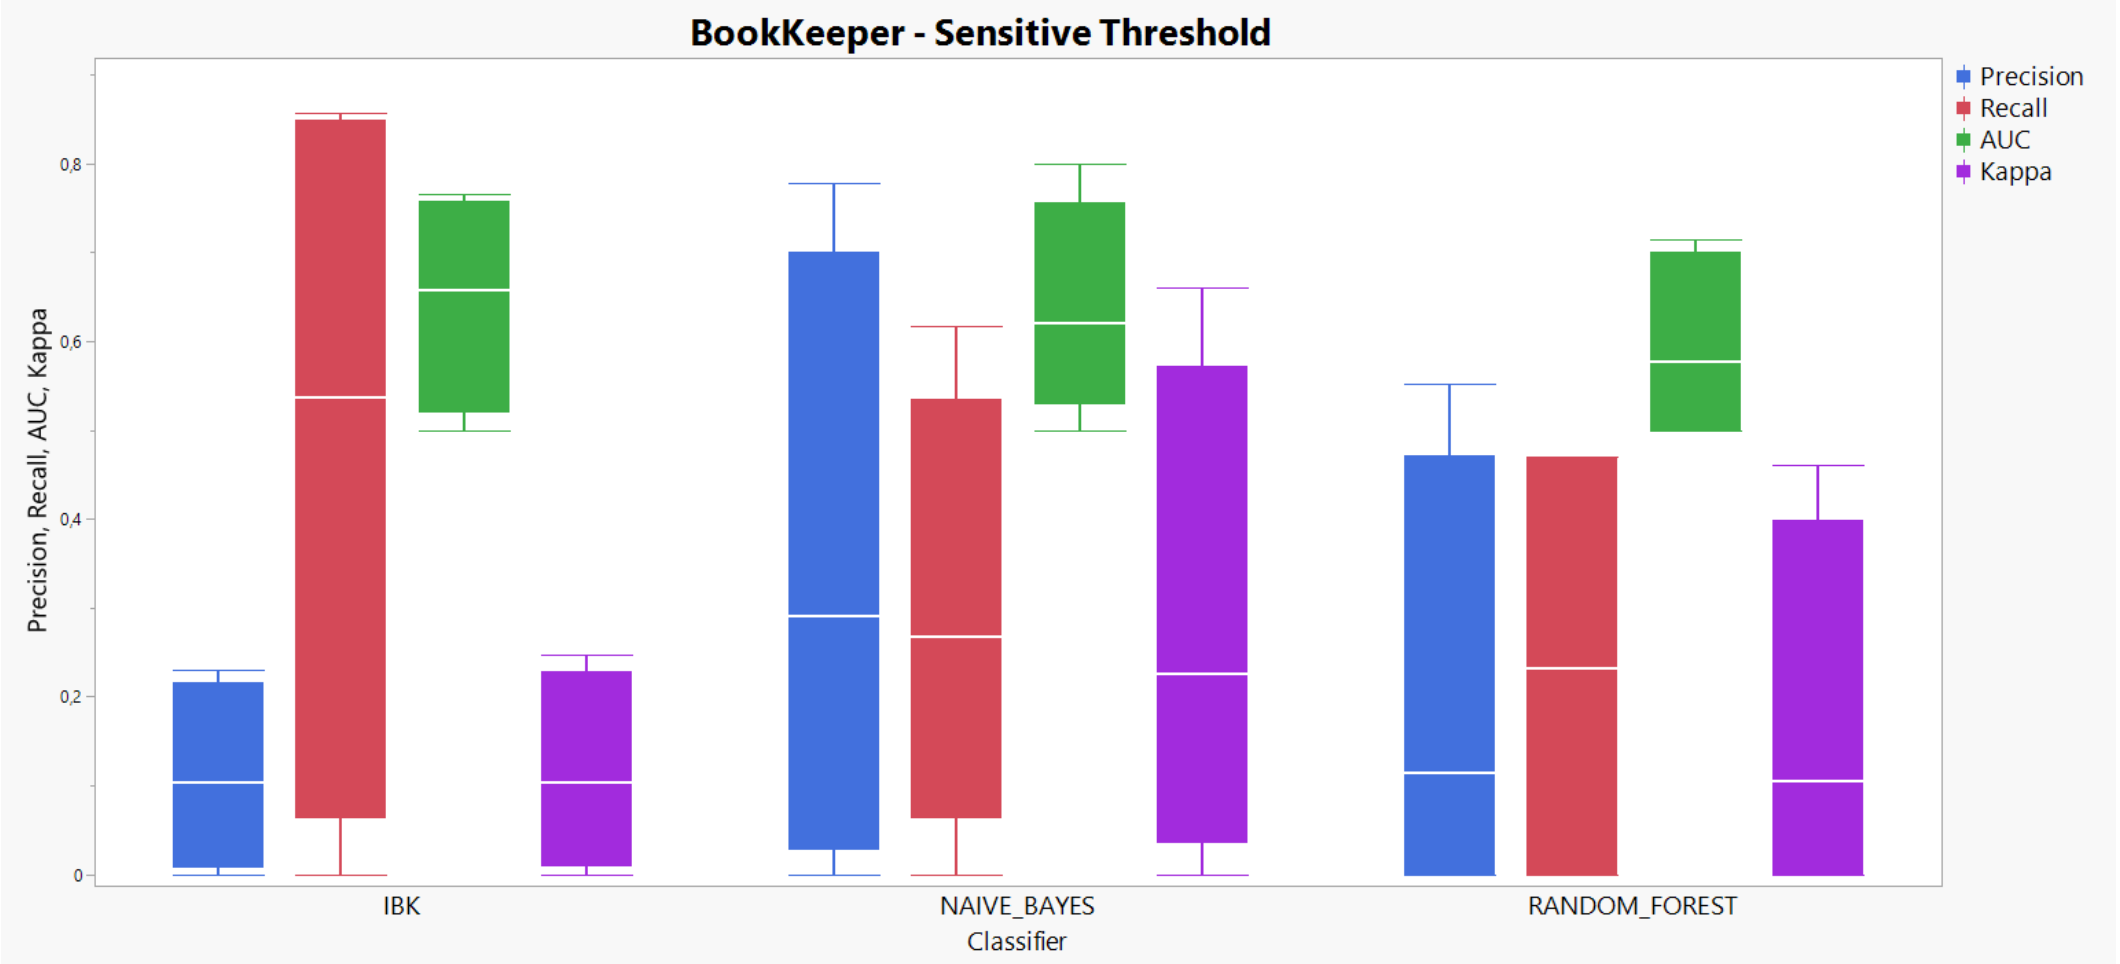

Risultati: BookKeeper – Sensitive Learning

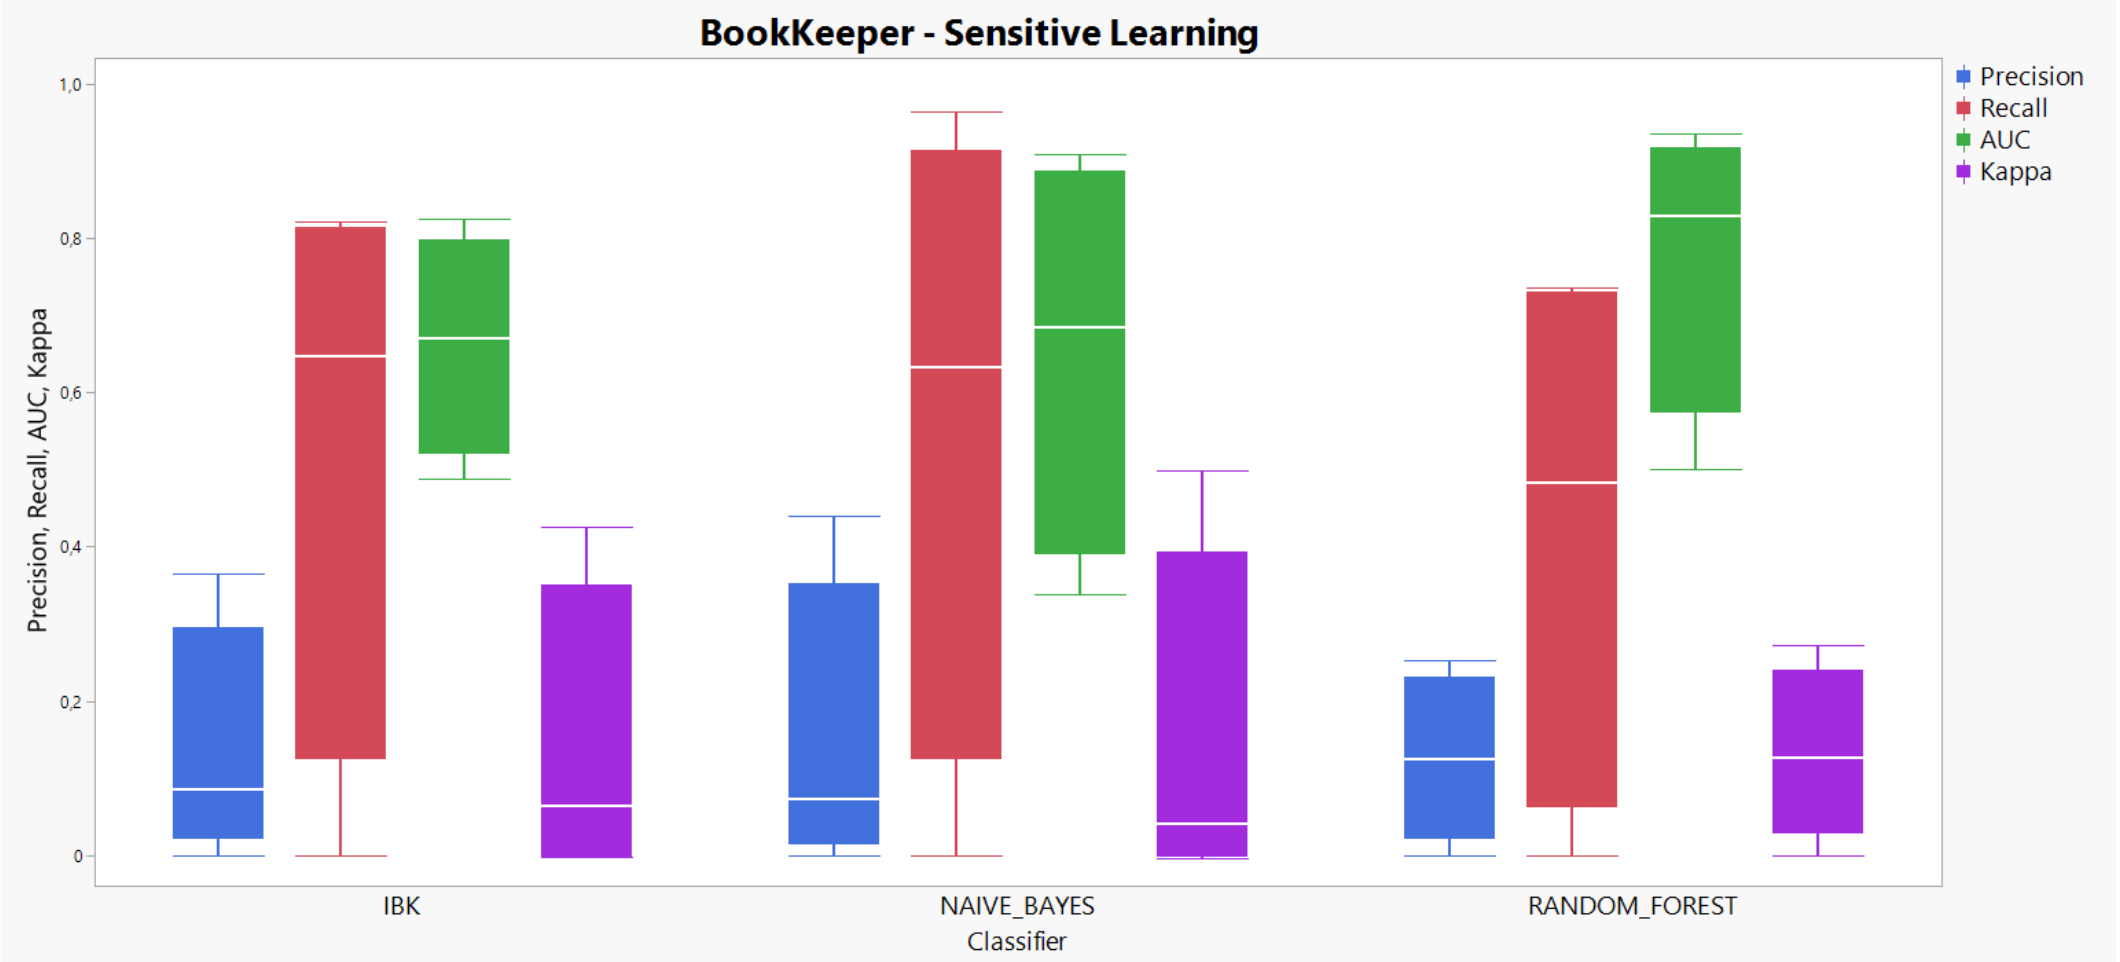

Risultati: BookKeeper - considerazioni

- **PREMESSA**: BookKeeper ha poche releases, dunque, il processo di validazione con Walk Forward è risultato nell'esecuzione di sole 5 run. Di conseguenza, le distribuzioni rappresentate dai box plot raffigurano un campione di dimensioni limitate, composto da pochi sample points.

- **No Cost Sensitivity***:* tutti i classificatori hanno Recall comparabile, ma *Naive Bayes* ha la precisione più elevata, considerando la mediana. Inoltre, anche Kappa è il migliore, mentre AUC risulta essere leggermente inferiore a quella di *Random Forest. IBK* è sicuramente il classificatore peggiore, mentre il migliore è **Naive Bayes**.

- **Sensitive Threshold**: rispetto a *No Cost Sensitivity*, non si ha un netto miglioramento in generale. Si nota un particolare decremento della Recall per *Random Forest*, mentre *Naive Bayes* continua ad avere la *Precision* migliore. Sebbene *NaiveBayes* e *IBK* siano assolutamente comparabili, si preferisce ancora **Naive Bayes,** in quanto ha un valore mediano di Kappa superiore.

- **Sensitive Learning**: i classificatori prevedono molto più spesso positivi (buggy); ciò è visibile in un complessivo aumento della Recall e nella contestuale diminuzione della Precision. Considerando anche Kappa ed AUC, stavolta il classificatore migliore è senza dubbio **Random Forest**.

Risultati: Syncope – No Cost Sensitivity

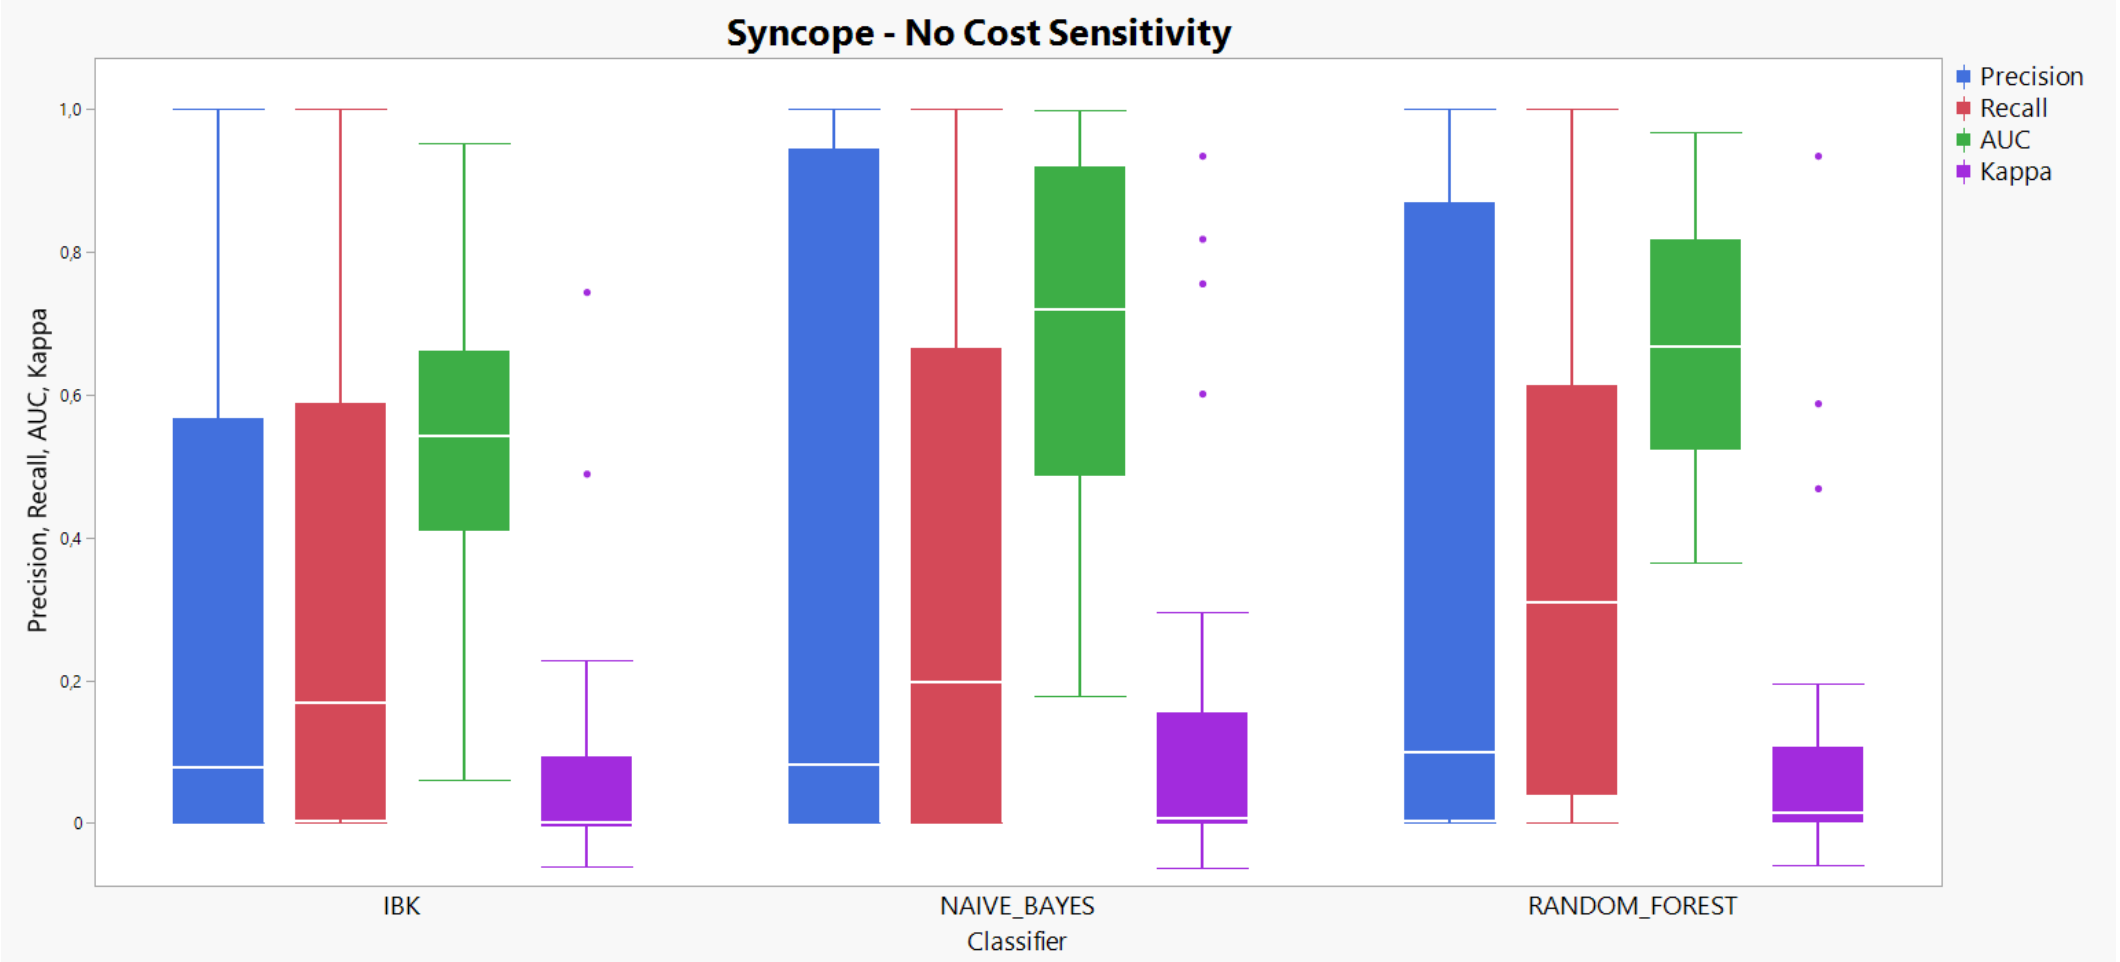

Risultati: Syncope – Sensitive Threshold

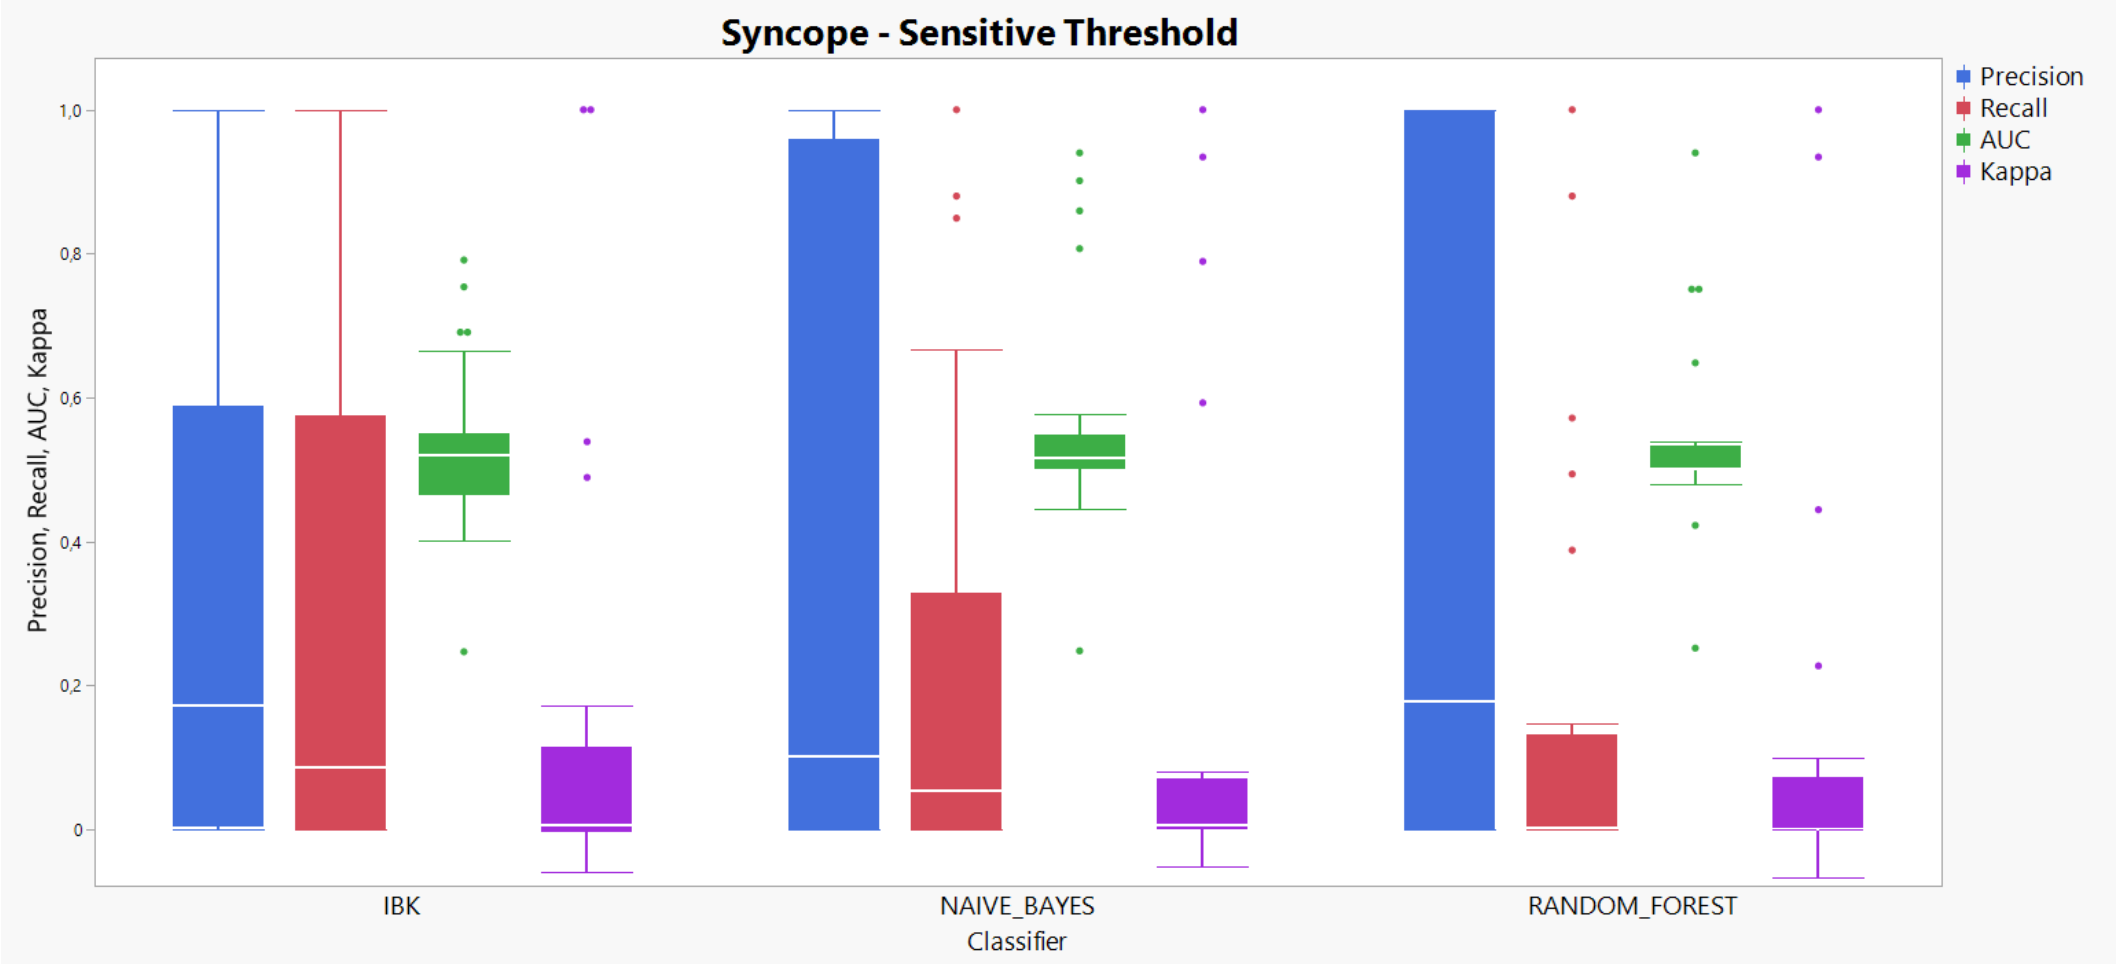

Risultati: Syncope – Sensitive Learning

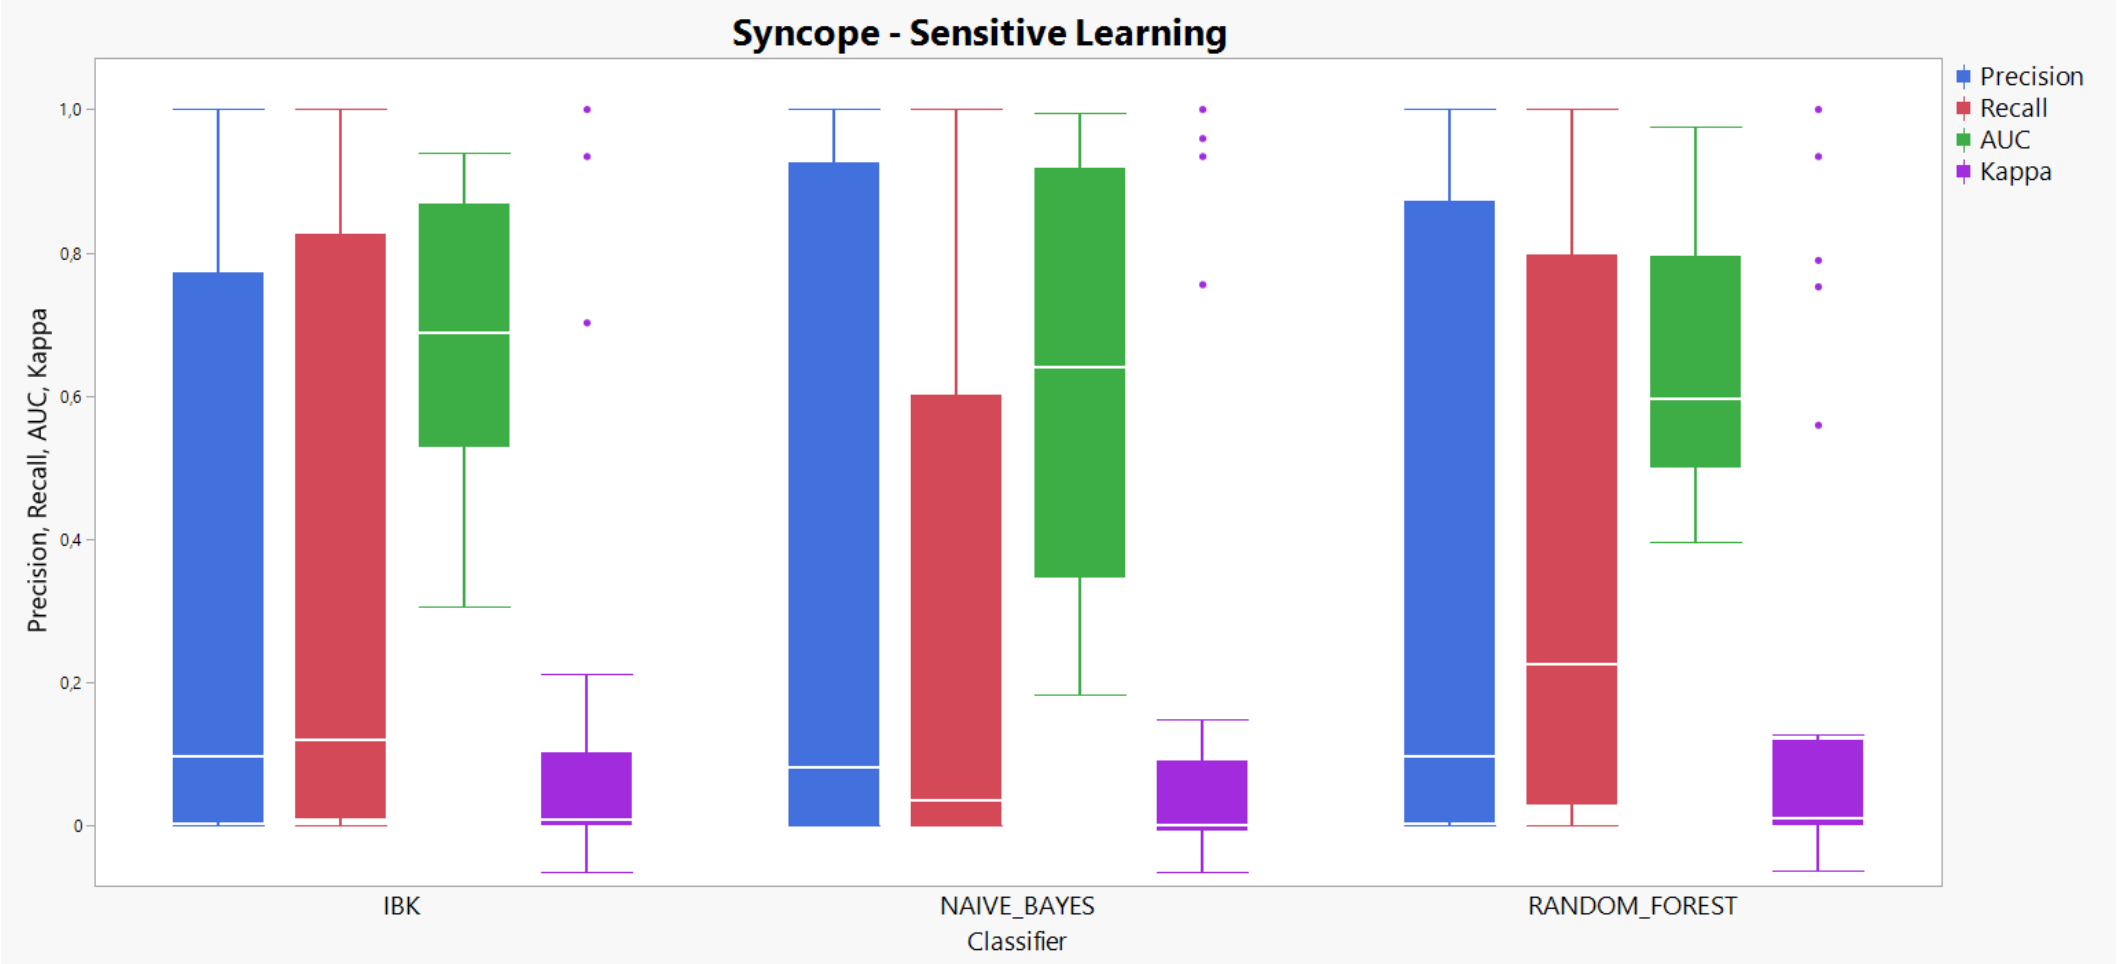

Risultati: Syncope - considerazioni

- **No Cost Sensitivity**: dal grafico è evidente che il classificatore peggiore sia *IBK*. La mediana della Precision dei tre classificatori coincide, ma a livello di distribuzione, quella di *Naive Bayes* è migliore, così come per l'AUC. Il Kappa è molto basso per tutti e tre i classificatori. Il migliore è **Naive Bayes**.

- **Sensitive Threshold**: si ha un inaspettato calo della Recall sia per *Naive Bayes* che per *Random Forest*, in cambio di un lieve miglioramento della Precision. Ma, complessivamente, sia AUC che Kappa calano di molto, registrando un peggioramento generale per tutti e tre i classificatori. È difficile affermare quale dei tre sia il migliore.

- **Sensitive Learning**: come atteso, c'è un aumento della Recall, anche se la mediana resta comunque abbastanza bassa. La Precision dei tre classificatori è simile, ma quello che ottiene miglioramenti sensibili grazie a questa politica di cost sensitivity è senza dubbio **IBK**, che risulta essere il migliore dei tre.

Riferimenti

- Repository GitHub con codice sorgente: https://github.com/AndreaPepe/MLforSE

- SonarCloud: https://sonarcloud.io/summary/overall?id=AndreaPepe_SyncopeDataMining